



LDATS2310

Deep Learning for Insurance and Finance

Projet réalisé par :

Davy Romaric KAMGA BOPDA

Faculté des Sciences

Supervisé par : Donatien Hainaut

Date : 29 juin 2026

1 À propos des données

Ce projet analyse 87 228 contrats d'assurance flotte automobile décrits par 22 variables contractuelles, géographiques et comportementales, en vue de prédire la **fréquence de sinistres**, définie par :

$$f_i = \frac{N_i}{\nu_i},$$

où N_i est le nombre de sinistres et ν_i l'exposition au risque du contrat i .

Le travail s'articule autour de deux axes : **(i)** l'ajustement d'un GLM Poisson et de quatre réseaux de neurones profonds, avec interprétation via PDP et courbes ICE ; **(ii)** un clustering des contrats par compression dans un espace latent à l'aide d'auto-encodeurs (AE) et d'auto-encodeurs variationnels (VAE).

Toutes les variables explicatives sont catégorielles et encodées en *one-hot*. Deux stratégies sont adoptées : les AE/VAE conservent toutes les modalités ($n \times 57$), tandis que le GLM et les réseaux de neurones suppriment la modalité de référence pour éviter la multicolinéarité ($n \times 44$). La modalité de référence est définie comme la catégorie la plus exposée.

2 Analyse exploratoire

Le jeu de données brut `train_contrats.csv` contient 87 228 observations et 23 variables portant sur des contrats de flotte automobile. Avant toute modélisation, plusieurs étapes de nettoyage et de typage ont été nécessaires.

2.1 Suppression des variables non pertinentes

Trois catégories de variables ont été retirées du jeu de données.

Variables temporelles redondantes. Les colonnes `Date_Deb_Situ`, `Date_Fin_Situ` et `ANNEE` ont servi à construire la variable `Exposition_au_risque`. Une fois cette variable dérivée disponible, les variables sources ne portent plus d'information additionnelle et ont donc été supprimées.

Variable sans variabilité. La variable `Categorie_ensemble` ne présente qu'une seule modalité pour l'ensemble des observations. Cette variable constante n'apporte aucune information discriminante et a été exclue.

2.2 Traitement des valeurs manquantes

L'analyse des valeurs manquantes a révélé que la variable Valeur_assuree présentait un taux de non-définition (*ND*) de 99,85 %, soit 87 093 observations sur 87 228. Ce taux rend toute imputation statistiquement incohérente ; la variable a donc été supprimée. Après ces traitements, le jeu de données ne contient aucune variable ayant les valeurs manquantes.

2.3 Typage des variables

Dans la suite, nous considérerons que l'ensemble des variables explicatives est de nature catégorielle, qu'elles soient ordinales ou nominales. En effet, certaines variables qui pourraient a priori être perçues comme quantitatives, telles que ValeurPuissance, présentent un nombre limité de modalités ainsi qu'une variabilité très faible, ce qui justifie leur traitement en tant que variables catégorielles.

Variables ordinales.

- Classe_Age_Situ_Cont : de « ≤ 1 an » à « > 5 ans » ;
- Age_du_vehicule : « ≤ 5 ans » ou « > 5 ans » ;
- Segment, ValeurPuissance et Nombre_vehicule : ordre numérique croissant.

Variables nominales. Mode_gestion, Zone, Fractionnement, franchise, FORMULE, Activite, Type_Apporteur et Creation_Entr.

2.4 Construction de la variable cible

La variable à modéliser est la **fréquence de sinistres** : $f_i = \frac{N_i}{\nu_i}$, $\nu_i \in (0, 1]$. Le premier graphique de la figure 1 révèle une structure fortement déséquilibrée : 95,1 % des contrats n'enregistrent aucun sinistre, 4,5 % en déclarent exactement un, et moins de 0,1 % en comptent trois ou plus. Le second graphique confirme l'asymétrie à droite de la fréquence : médiane nulle et moyenne $\bar{f} = 0,1262$, signe d'une distribution à queue épaisse caractéristique d'un portefeuille de flottes.

2.5 Analyse univariée de quelques variables explicatives

En raison du nombre élevé de variables, nous présentons une analyse sélective. Pour chaque variable, le graphique de gauche indique la distribution des contrats entre les modalités, et le graphique de droite compare la fréquence moyenne observée par modalité à la fréquence globale $\bar{f} = 0,1262$.

Analyse de la sinistralité




FIGURE 1 – Distribution du nombre et de la fréquence de sinistres




FIGURE 2 – Distribution et fréquence moyenne — Zone et Franchise

Zone géographique (Voir figure 2). La zone 3 concentre 36,8% des contrats. La zone 5, peu représentée (10,0%), affiche la fréquence la plus élevée (0,1700, soit +34,7% au-dessus de la moyenne), tandis que les zones 1 et 2 présentent les fréquences les plus faibles (0,1091 et 0,1160).

Franchise (Voir figure 2). La modalité « 2. 1–200 » domine le portefeuille (45,1%). Les fréquences sont globalement homogènes entre les modalités (écart maximal $\pm 0,02$), à l'exception de la franchise nulle qui présente la sinistralité la plus élevée (0,1444). L'effet discriminant reste modéré.

Activité du client (Voir figure 3). Les modalités 1 et 8 affichent des fréquences supérieures à la moyenne (0,1447 et 0,1479), tandis que les modalités 3 et 6 présentent les niveaux les plus faibles (0,1023 et 0,1010).

Âge du véhicule (Voir figure 3). Les véhicules récents (≤ 5 ans, 67% du portefeuille) affichent $\bar{f} = 0,1490$ contre 0,0799 pour les plus anciens, soit une réduction




FIGURE 3 – Distribution et fréquence moyenne — Activité et Âge du véhicule

de risque de 46,4 %. Il s'agit de l'une des variables les plus discriminantes.




FIGURE 4 – Distribution et fréquence moyenne — Puissance et Formule

Puissance du véhicule (Voir figure 4). La relation puissance–sinistralité n'est pas monotone : les niveaux faibles (1 et 2) présentent des fréquences nettement inférieures à la moyenne (0,0585 et 0,0557), la sinistralité croît jusqu'au niveau 9 (0,1726), puis décroît (0,0633 pour le niveau 11).

Formule / Type de contrat (Voir figure 4). La formule 3 domine avec 78,2 % des contrats. Les formules 4 et 5 affichent des fréquences inférieures à la moyenne (0,1034 et 0,0999), suggérant un lien entre le type de couverture et le niveau de risque.

2.6 Analyse inférentielle — Test du Khi-deux

Pour mesurer l'association entre les variables explicatives et la sinistralité, nous avons construit une variable indicatrice (construite **exclusivement pour ce test**) $1_{\{N_i > 0\}}$, valant 1 si le contrat enregistre au moins un sinistre et 0 sinon. Le test du Khi-deux, adapté à deux variables catégorielles, est ensuite appliqué à chaque prédicteur. Le V de Cramér quantifie la force de l'association. Les résultats sont présentés dans le tableau 1.

TABLE 1 – Test du Khi-deux — Association avec la sinistralité

Variable	χ^2	p -valeur	DDL	V de Cramér	Significatif
Mode_gestion	607,03	$4,95 \times 10^{-134}$	1	0,0834	Oui
Age_du_vehicule	344,46	$6,83 \times 10^{-77}$	1	0,0628	Oui
Activite	152,81	$1,04 \times 10^{-29}$	7	0,0419	Oui
ValeurPuissance	140,47	$3,37 \times 10^{-25}$	10	0,0401	Oui
Zone	139,24	$2,59 \times 10^{-28}$	5	0,0400	Oui
Type_Aporteur	84,18	$5,24 \times 10^{-19}$	2	0,0311	Oui
Classe_Age_Situ_Cont	43,69	$2,63 \times 10^{-8}$	5	0,0224	Oui
FORMULE	41,54	$5,02 \times 10^{-9}$	3	0,0218	Oui
Fractionnement	39,27	$2,97 \times 10^{-9}$	2	0,0212	Oui
franchise	21,95	$5,36 \times 10^{-4}$	5	0,0159	Oui
Creation_Entr	16,26	$5,51 \times 10^{-5}$	1	0,0137	Oui
Segment	14,13	$1,70 \times 10^{-4}$	1	0,0127	Oui
Nombre_vehicule	0,00	1,000	1	0,0000	Non

Toutes les variables sont significativement associées à la sinistralité au seuil de 5 %, à l'exception de Nombre_vehicule. Cependant, les V de Cramér restent faibles (tous inférieurs à 0,09), ce qui indique que chaque variable prise isolément n'explique qu'une fraction modeste de la variabilité de la sinistralité. C'est précisément pourquoi des modèles multivariés sont nécessaires.

3 Apprentissage supervisé

3.1 Modèle de référence — GLM Poisson

Cadre de modélisation

Le GLM Poisson modélise la fréquence de sinistres via un lien logarithmique avec offset :

$$\log(\mathbb{E}[f_i | \mathbf{x}_i]) = \log(\nu_i) + \mathbf{x}_i^\top \boldsymbol{\beta}, \quad f_i = \frac{N_i}{\nu_i},$$

où ν_i est l'exposition au risque et $\mathbf{x}_i$ le vecteur de caractéristiques du contrat i . Le modèle est estimé via la classe `TweedieRegressor(power=1, alpha=0.0, link='log', max_iter=500)` du package *scikit-learn*, où la fréquence observée f_i constitue la variable réponse et l'exposition ν_i le poids de chaque observation

Encodage des variables

Toutes les variables explicatives étant catégorielles, elles sont encodées en *one-hot* (OHE). La modalité de référence supprimée de la matrice pour éviter toute multicollinéarité est définie pour les variables nominales comme la catégorie présentant la plus grande exposition cumulée, et pour les variables ordinales comme la première catégorie dans l'ordre naturel. La matrice $\mathbf{X}$ obtenue est de dimension $n \times 44$.

Résultats

L'intercept estimé vaut $\hat{\beta}_0 = -1,7734$, soit $\exp(\hat{\beta}_0) = 0,1698$, ce qui correspond à la fréquence prédite pour un contrat dont toutes les variables sont à leur modalité de référence. Le tableau 2 présente les déviations et fréquences moyennes obtenues sur les deux jeux de données.

TABLE 2 – Résultats du GLM Poisson — entraînement et validation

Métrique	Entraînement	Validation
Déviance moyenne	0,6627	0,6231
Déviance totale	20 448,29	4 787,44
Fréquence moy. observée	0,1202	0,1119
Fréquence moy. prédite	0,1203	0,1199

La déviance de validation (0,6231) est inférieure à celle d'entraînement (0,6627), indiquant l'absence d'overfitting. Sur le jeu d'entraînement, le GLM est quasi-parfaitement calibré (0,1202 observée contre 0,1203 prédite). Sur la validation, un léger écart

subsiste (0,1119 observée contre 0,1199 prédite), révélant un biais résiduel. Ces déviations constituent notre **benchmark** de référence pour la comparaison avec les réseaux de neurones.

3.2 Réseaux de neurones — Architectures et entraînement

Préparation des données

Toutes les variables explicatives étant catégorielles, elles ont été encodées en *one-hot* (OHE) avec suppression de la modalité de référence. Ainsi, toute variable comportant k niveaux est représentée par $k - 1$ indicatrices binaires (valeurs 0 ou 1), évitant la multicollinéarité parfaite.

Principes communs

Quatre architectures de réseaux de neurones profonds ont été ajustées. Tous partagent les paramètres suivants :

- **Variable réponse** : $\mathbf{Y} = [f_i, \nu_i]^\top$;
- **Fonction de perte** : déviance de Poisson : $\mathcal{L}(\boldsymbol{\theta}) = 2 \sum_{i=1}^n \nu_i \left(f_i \log \frac{f_i}{\hat{f}_i} - f_i + \hat{f}_i \right)$;
- **Activation de sortie** : `exponential` garantissant $\hat{f}_i > 0$;
- **Optimiseur** : Adam ($\text{lr} = 8 \times 10^{-3}$) ;
- **Split** : 80 % entraînement et 20 % validation .

Architectures

Le tableau 3 décrit les quatre architectures testées.

TABLE 3 – Architectures des quatre réseaux de neurones

Modèle	Couches cachées	Activation	Régularisation
NN1_Simple	64 → 32 → 16 → 1	ReLU / Exponential	Aucune
NN2_L2_Dropout	64 → Drop(0,3) → 32 → Drop(0,3) → 16 → Drop(0,3) → 1	ReLU / Exponential	L2 ($\lambda = 10^{-3}$) + Dropout
NN3_Deep	128 → Drop(0,2) → 64 → Drop(0,2) → 32 → Drop(0,2) → 16 → Drop(0,2) → 1	ReLU / Exponential	Dropout
NN4_Tanh_L1L2	64 → 32 → Drop(0,3) → 16 → Drop(0,3) → 1	Tanh / Exponential	L1L2 ($\lambda_1 = \lambda_2 = 10^{-4}$) + Dropout

Résultats et courbes d'apprentissage

Les courbes de la figure 5 montrent une convergence rapide pour tous les modèles : la déviance de validation atteint son minimum entre l'époque 6 (NN1) et l'époque 26 (NN4). On observe que la déviance de validation se stabilise systématiquement en dessous de la déviance d'entraînement, signe d'une bonne généralisation sans overfitting.




FIGURE 5 – Courbes d'apprentissage — 4 réseaux de neurones

TABLE 4 – Résultats des 4 réseaux de neurones

Modèle	Époques	Dev. moy. train	Dev. moy. val	Fréq. prédite val
NN1_Simple	97	0,6558	0,6254	0,1289
NN2_L2_Dropout	107	0,6522	0,6257	0,1282
NN3_Deep	102	0,6473	0,6265	0,1341
NN4_Tanh_L1L2	117	0,6606	0,6223	0,1134

Fréquence observée val : 0,1119

Tableau comparatif — GLM et 4 NN

Le tableau 5 montre que NN4_Tanh_L1L2 obtient la déviance de validation la plus faible (0,6223), devançant légèrement le GLM (0,6231). Notons que les gains sont modestes entre les modèles : l'écart entre le meilleur NN et le GLM est de seulement 0,0008 en déviance moyenne. Ce résultat s'explique par la nature purement catégorielle des variables : le GLM avec lien log capte déjà efficacement les effets additifs, laissant peu de marge aux non-linéarités que les NN pourraient exploiter. NN4_Tanh_L1L2 est retenu comme meilleur modèle pour la suite de l'analyse parmi les modèles NN.

TABLE 5 – Comparaison GLM + 4 NN — trié par déviance de validation croissante

Modèle	Dev. moy. train	Dev. moy. val	Dev. tot. train	Dev. tot. val
NN4_Tanh_L1L2	0,6606	0,6223	20 382,90	4 781,36
GLM_Poisson	0,6627	0,6231	20 448,29	4 787,44
NN1_Simple	0,6558	0,6254	20 235,07	4 805,03
NN2_L2_Dropout	0,6522	0,6257	20 133,32	4 806,97
NN3_Deep	0,6473	0,6265	19 972,16	4 813,23

3.3 Comparaison des prédictions par sous-groupes

Comparaison globale

Sur le jeu de validation, les fréquences moyennes pondérées globales sont résumées dans le tableau 6.

TABLE 6 – Comparaison globale — jeu de validation

Modèle	Fréquence moy. pondérée
Observée	0,1119
GLM Poisson	0,1199
NN4_Tanh_L1L2	0,1134

Le NN4_Tanh_L1L2 est globalement mieux calibré (0,1134 contre 0,1119 observé), tandis que le GLM surestime légèrement la fréquence globale (0,1199). Ces écarts restent cependant modérés dans les deux cas.

Comparaison par sous-groupes

Les figures 16 et 17 (voir annexe A) présentent, pour chaque modalité des principales variables, la fréquence observée et la fréquence prédite sur le jeu de validation.

Variables bien captées par les deux modèles. Globalement, les modalités des variables Fractionnement et Age_du_vehicule sont bien prédites par les deux modèles.

Variables présentant des écarts notables.

- **Zone** : le GLM surestime sensiblement la zone 4 (0,136 prédit contre 0,123 observé) et sous-estime la zone 1 (0,104 contre 0,090). Le NN corrige partiellement ces écarts mais ne les élimine pas totalement.

- **ValeurPuissance** : les niveaux extrêmes (10, 2 et 11) sont mal capturés par les deux modèles, avec des écarts pouvant dépasser 0,05.
- **FORMULE** : la formule 2, quasi absente du portefeuille (0,0 %), affiche une fréquence observée nulle sur la validation mais une prédiction non nulle pour les deux modèles ($\approx 0,08$), ce qui illustre la difficulté à modéliser des modalités très peu représentées.
- **Classe_Age_Situ_Cont** : le GLM prédit une fréquence supérieure à la réalité pour presque toutes les anciennetés de contrat. Le NN suit le même schéma mais avec des écarts légèrement réduits.

Dans l'ensemble, **NN4_Tanh_L1L2** suit mieux la **tendance observée** que le GLM, notamment pour les variables *Zone*, *Activite* et *Classe_Age_Situ_Cont*, sans pour autant éliminer tous les biais résiduels.

3.4 Ajustement du biais — Balance Property

Principe

Un modèle bien calibré doit satisfaire la **propriété d'équilibre** (*balance property*) : le nombre total de sinistres prédit doit égaler le nombre total observé :

$$\sum_{i=1}^n \nu_i \hat{f}_i = \sum_{i=1}^n N_i.$$

Lorsque cette propriété n'est pas vérifiée par sous-groupe, un biais systématique est corrigé par recalibration. Pour chaque groupe g d'une variable catégorielle, un facteur correctif est appliqué :

$$\alpha_g = \frac{\bar{f}_g^{\text{obs}}}{\bar{f}_g^{\text{pred}}}, \quad \hat{f}_i^* = \alpha_{g(i)} \times \hat{f}_i,$$

où $\bar{f}_g$ désigne la fréquence moyenne pondérée par l'exposition sur le groupe g . Cette procédure est appliquée séquentiellement sur l'ensemble des variables catégorielles disponibles, produisant les modèles corrigés **GLM** et **NN**.

Résultats après correction

Interprétation. Après correction, les points rouges et verts sont quasi superposés pour la quasi-totalité des variables et des modalités. La recalibration réduit la déviance de 0,0054 pour le GLM et de 0,0048 pour le NN. Le gain est modeste mais systématique, confirmant que les biais résiduels avant correction étaient structurés




FIGURE 6 – Section 1.1b — Fréquence observée vs GLM réajusté (GLM)




FIGURE 7 – Section 1.1b — Fréquence observée vs NN réajusté (NN) — NN4_Tanh_L1L2

par variable plutôt qu'aléatoires. Notons que les résultats de GLM et NN sont très proches : la correction tend à homogénéiser les performances des deux modèles, ce qui confirme que l'essentiel de l'information contenue dans les variables catégorielles est déjà capté par les deux approches.

TABLE 7 – Déviance avant et après ajustement du biais — jeu de validation

Modèle	Dév. moy. avant	Dév. moy. après	Gain (Δ)
GLM Poisson	0,6231	0,6177	0,0054
NN4_Tanh_L1L2	0,6223	0,6175	0,0048

3.5 Interprétation des modèles — Partial Dependence Plots (PDP)

Le graphique de dépendance partielle (*Partial Dependence Plot*, PDP) mesure l'effet marginal moyen d'une variable sur la fréquence prédite, toutes autres variables maintenues à leur distribution empirique :

$$\hat{D}_S(v) = \frac{1}{n} \sum_{i=1}^n f(v, \mathbf{x}_C^{(i)}),$$

où v est la modalité testée et $\mathbf{x}_C^{(i)}$ regroupe les autres caractéristiques de l'individu i . La figure 8 compare les PDP du GLM et de NN4_Tanh_L1L2 pour l'ensemble des variables, la ligne pointillée indiquant la fréquence globale $\bar{f} = 0,1119$.

Interprétation du PDP des variables (figure 8).

- **Age_du_vehicule** est la variable la plus discriminante : les véhicules récents (≤ 5 ans) affichent une fréquence prédite nettement supérieure à la moyenne ($\approx 0,134$ pour le GLM, $0,134$ pour le NN), tandis que les véhicules anciens tombent à $0,071$ (GLM) et $0,065$ (NN), soit une réduction de risque de près de 50 %.
- **Zone** présente une forte hétérogénéité : la zone 5 concentre les fréquences les plus élevées ($0,151$ pour le GLM, $0,160$ pour le NN), tandis que les zones 1 et 2 se situent nettement en dessous de la moyenne globale ($\approx 0,104$).
- **FORMULE** et **franchise** montrent une tendance décroissante : les formules et niveaux de franchise plus élevés sont associés à des fréquences prédites plus faibles, ce qui est économiquement cohérent.
- **Mode_gestion**, **Fractionnement** et **Nombre_vehicule** présentent des effets plus modérés, avec des écarts entre modalités inférieurs à $0,02$.




FIGURE 8 – PDP — Variables (GLM Poisson vs NN4_Tanh_L1L2)

— **ValeurPuissance** révèle une relation en forme de cloche non monotone : la sinistralité est minimale pour les puissances faibles (niveau 2 : $\approx 0,08$), croît jusqu'au niveau 9 (0,162 pour le GLM, 0,152 pour le NN), puis décroît fortement pour les niveaux très élevés (niveau 11 : 0,092 et 0,076)

GLM / NN. Dans l'ensemble, le GLM et le NN4_Tanh_L1L2 produisent des PDP très similaires, ce qui confirme que les effets marginaux sont principalement additifs et linéaires sur l'échelle log. Les divergences les plus marquées concernent **Valeur-Puissance** aux niveaux extrêmes où le NN prédit des fréquences légèrement plus faibles.

3.6 Analyse locale — SHAP et LIME sur deux polices

Présentation des deux polices

Afin d'illustrer la capacité d'interprétation locale des modèles, nous analysons deux contrats aux profils contrastés : la **police 50612**, qui n'a enregistré aucun sinistre sur la période, et la **police 16863**, qui en a déclaré trois pour une exposition de seulement $\nu = 0,21$ an, aboutissant à une fréquence observée extrême de 14,29. Le tableau 8 résume leurs caractéristiques.

TABLE 8 – Caractéristiques des deux polices analysées

Variable	Police 50612	Police 16863
Classe_Age_Situ_Cont	2–3 ans	> 5 ans
Creation_Entr	2	1
Mode_gestion	P	N
Zone	1	1
Segment	1	1
Fractionnement	T	T
Exposition_au_risque	1,00	0,21
Age_du_vehicule	> 5 ans	≤ 5 ans
franchise	5. 401–600	4. 301–400
Nombre_vehicule	1	1
FORMULE	5	5
Activite	1	8
Type_Aporteur	1	1
ValeurPuissance	7	9
Nombre de sinistres	0	3
Fréquence observée	0,0000	14,2857
Prédiction GLM	0,1293	0,2118
Prédiction NN4_Tanh_L1L2	0,1165	0,2094

Avant toute analyse, notons que la fréquence moyenne prédite par nos modèles pour l'ensemble du portefeuille est $\mathbb{E}[f(\mathbf{x})] \approx 0,1119$. Analyser une police revient donc à comprendre comment ses caractéristiques font dévier la prédiction individuelle $f(\mathbf{x}_i)$ de cette référence globale.

Méthodes d'interprétation locale

Deux outils sont mobilisés :

SHAP (*Shapley additive explanations*) décompose la prédiction en une somme de contributions individuelles fondées sur la théorie des jeux : $f(\mathbf{x}_i) = \mathbb{E}[f(\mathbf{X})] + \sum_{j=1}^p \phi_j(\mathbf{x}_i)$ où ϕ_j est la valeur de Shapley de la variable j pour l'individu i .

LIME (*Local interpretable model-agnostic explanations*) construit un modèle linéaire de substitution dans le voisinage de $\mathbf{x}_i$, fournissant des contributions locales c_j dont la somme reconstruit approximativement la prédiction. Les figures SHAP et LIME du GLM sont présentées en annexe C. Nous concentrons l'analyse sur NN4_Tanh_L1L2, meilleur modèle retenu.

Police 50612 — Aucun sinistre




FIGURE 9 — SHAP — Police 50612 — NN4_Tanh_L1L2

La police 50612 est un contrat à pleine exposition ($\nu = 1,00$) sans sinistre déclaré. Le NN prédit $\hat{f} = 0,1165$, légèrement supérieur à la moyenne globale. Les graphiques SHAP et LIME convergent vers la même interprétation : la prédiction est tirée à la hausse par rapport à la référence, mais certaines caractéristiques du contrat exercent un effet protecteur.




FIGURE 10 — LIME — Police 50612 — NN4_Tanh_L1L2

- **Facteurs haussiers (SHAP).** Le NN identifie Age_du_vehicule_>5 ans comme le principal contributeur positif (+0,0187) : le fait que le véhicule soit ancien est associé dans le portefeuille à une sinistralité plus élevée, conformément aux résultats des PDP. L'ancienneté du contrat (Classe_Age_Situ_Cont_1-2 ans, +0,0098) et l'appartenance à la zone 4 (+0,0047) contribuent également à la hausse, de même que les indicateurs de puissance intermédiaire (ValeurPuissance_7, +0,0061).
- **Facteurs baissiers (SHAP et LIME).** Activite_6 constitue la contribution négative dominante dans les deux méthodes (−0,0372 en SHAP, −0,0173 en LIME) : le secteur d'activité de cette entreprise est structurellement associé à une sinistralité inférieure à la moyenne. La franchise élevée (franchise_4. 301-400) exerce un effet protecteur cohérent (−0,0132 en SHAP, −0,0078 en LIME). Le fractionnement annuel (Fractionnement_A, −0,0076 SHAP, −0,0056 LIME) et le mode de gestion N (−0,0060 SHAP, −0,0089 LIME) renforcent cet effet protecteur.

Police 16863 — Trois sinistres

La police 16863 présente un profil de risque élevé. Avec seulement $\nu = 0,21$ an d'exposition et 3 sinistres, la fréquence observée atteint 14,29. Le modèle prédit $\hat{f} = 0,2094$, soit +87 % au-dessus de la moyenne globale : ce contrat est correctement

identifié comme à risque élevé, même si l'ampleur de la sinistralité réelle reste très au-delà de toute prédiction raisonnable.




FIGURE 11 — SHAP — Police 16863 — NN4_Tanh_L1L2 (Prédiction : 0,2094 | Observée : 14,2857)




FIGURE 12 — LIME — Police 16863 — NN4_Tanh_L1L2 (Prédiction : 0,2094 | Observée : 14,2857)

— **Facteurs haussiers (SHAP).** Zone_5 est le contributeur positif le plus important (+0,0347) : cette zone présente la sinistralité la plus élevée du portefeuille, comme l’avaient déjà montré les PDP et l’analyse univariée. L’absence

d'un véhicule ancien ($\text{Age_du_vehicule_}>5 \text{ ans} = 0$, soit un véhicule ≤ 5 ans) contribue positivement à hauteur de $+0,0298$: les véhicules récents sont associés à une fréquence plus élevée, ce qui est cohérent avec les résultats globaux. L'ancienneté du contrat ($\text{Classe_Age_Situ_Cont_4-5 ans}$, $+0,0139$) et le fait de ne pas appartenir aux activités à faible risque (Activite_3 , $+0,0148$; Activite_6 , $+0,0106$) contribuent également à la hausse.

- **Facteurs baissiers (SHAP).** Activite_7 constitue le principal frein à la prédiction ($-0,0351$) : ce secteur d'activité, présent pour cet assuré (valeur = 1), est associé à une sinistralité plus modérée dans le portefeuille. Le mode de gestion N ($-0,0137$) et la puissance du véhicule (ValeurPuissance_3 , $-0,0114$) exercent également un effet modérateur, limitant la prédiction à $0,2094$ malgré la zone géographique à risque élevé.

4 Apprentissage non supervisé — Auto-encodeurs et clustering

L'objectif de cette section est de construire une représentation compressée des contrats à partir des 57 variables binaires issues de l'encodage *one-hot* complet (drop_first=False), puis d'exploiter cet espace latent pour regrouper les contrats en segments homogènes de risque via l'algorithme K-means. Deux familles de modèles sont entraînées : **deux auto-encodeurs classiques** (AE) minimisant la BCE, et **deux auto-encodeurs variationnels** (VAE) minimisant la borne inférieure variationnelle ($-\mathcal{L}_{\text{ELBO}}$).

4.1 Architectures et pertes

Auto-encodeurs classiques (AE)

Les deux AE reçoivent en entrée le vecteur de dimension 57 et reconstruisent une sortie de même dimension. La perte de reconstruction est la **Binary Cross-Entropy** :

$$\mathcal{L}_{\text{BCE}}(\mathbf{x}, \hat{\mathbf{x}}) = -\frac{1}{57} \sum_{j=1}^{57} \left[x_j \log \hat{x}_j + (1 - x_j) \log(1 - \hat{x}_j) \right].$$

TABLE 9 – Architectures des auto-encodeurs classiques

Modèle	Architecture encodeur	Dim. latente	Perte
AE1_Simple	57 → 80 → 40 → 20 → 10	10	BCE
AE2_Deep	57 → 150 → 100 → 50 → 10 → 5	5	BCE

Auto-encodeurs variationnels (VAE)

Les deux VAE reposent sur un encodeur gaussien avec décodeur Bernoulli. La perte est la borne inférieure variationnelle négative :

$$-\mathcal{L}_{\text{ELBO}} = \underbrace{\mathcal{L}_{\text{BCE}}(\mathbf{x}, \hat{\mathbf{x}})}_{\text{reconstruction}} + \underbrace{D_{\text{KL}}(q_{\phi}(\mathbf{z} | \mathbf{x}) \parallel \mathcal{N}(\mathbf{0}, \mathbf{I}))}_{\text{régularisation}}.$$

TABLE 10 – Architectures des auto-encodeurs variationnels

Modèle	Architecture encodeur	Dim. latente	Perte
VAE1_BCE	57 → 100 → 50 → $(\boldsymbol{\mu}, \log \boldsymbol{\sigma}^2)$	10	−ELBO Bernoulli
VAE2_BCE_Deep	57 → 150 → 100 → 50 → 10 → $(\boldsymbol{\mu}, \log \boldsymbol{\sigma}^2)$	5	−ELBO Bernoulli

4.2 Qualité de la reconstruction

TABLE 11 – Métriques de reconstruction — AE classiques et VAE

Famille	Modèle	Dim. latente	Perte val. min	Époque opt.	KL empirique
AE	AE1_Simple	10	0,2347	98	0,6589
AE	AE2_Deep	5	0,0552	97	0,1478
VAE	VAE1_BCE	10	76,460	83	1,0211
VAE	VAE2_BCE_Deep	5	76,459	46	1,0211

La figure 13 synthétise les divergences KL empiriques (entropie croisée entre distribution originale et reconstruite) pour les quatre modèles. Les courbes d'apprentissage sont reportées en annexe D.

AE classiques. AE2_Deep domine nettement sur les deux métriques : BCE minimale de 0,0552 contre 0,2347 pour AE1_Simple, et KL quatre fois moindre (0,1478 contre 0,6589). Cette supériorité s'explique par la capacité accrue d'AE2_Deep (58,882




FIGURE 13 – Divergence KL empirique entre distribution originale et reconstruite

paramètres contre 15,047), qui lui permet de capturer des non-linéarités plus complexes dans les variables catégorielles. Les courbes d'apprentissage confirment une convergence saine sans sur-apprentissage pour les deux modèles (annexe D).

VAE. Les **pertes ELBO** sont **quasi identiques** (76,460 vs 76,459, écart négligeable) : la profondeur supplémentaire de VAE2_BCE_Deep n'apporte aucun gain mesurable. De même, les **divergences KL** sont **identiques** (1,0211), signe que le terme de régularisation domine l'apprentissage dans les deux cas. La convergence plus rapide de VAE2 (époque 46 contre 83) ne se traduit donc pas par une meilleure représentation.

Comparaison AE vs VAE. La divergence KL des VAE (1,0211) est nettement supérieure à celle des AE (0,6589 et 0,1478) : la contrainte variationnelle régularise l'espace latent vers $\mathcal{N}(0, \mathbf{I})$ au prix d'une fidélité de reconstruction moindre. Ce compromis reconstruction/régularisation aura des implications directes sur la qualité du clustering.

4.3 Clustering K-means sur l'espace latent

Pour chaque modèle, les coordonnées latentes sont soumises au K-means pour $k \in \{3, 5, 10, 12, 15, 18, 20\}$. La fréquence prédite pour chaque contrat est la **fréquence moyenne pondérée par l'exposition** de son cluster, estimée sur l'ensemble d'entraînement. La qualité est évaluée par la déviance de Poisson sur l'ensemble de validation. Les courbes d'optimisation (inertie et déviance en fonction de k) sont reportées en annexe E.

Sélection du nombre optimal de clusters

TABLE 12 – K-means — k optimal et déviance de Poisson (validation)

Modèle	Type	k optimal	Déviance de Poisson
AE1_Simple	AE	20	0,66651
AE2_Deep	AE	12	0,67201
VAE1_BCE	VAE	20	0,67255
VAE2_BCE_Deep	VAE	20	0,67402

AE1_Simple obtient la meilleure déviance (0,66651), malgré une qualité de reconstruction inférieure à AE2_Deep. Cela suggère qu'un espace latent de plus grande dimension ($\text{dim} = 10$ contre 5) et une architecture moins profonde conservent davantage d'information discriminante pour le clustering de risques. **La qualité de reconstruction et la qualité du clustering ne sont donc pas nécessairement alignées** : un espace latent moins compressé peut mieux séparer les profils de risque même s'il reconstruit moins fidèlement les données d'entrée. Pour les VAE, la contrainte variationnelle réduit la séparabilité des représentations, confirmant cette tendance.

Profils de fréquence par cluster — AE1_Simple (meilleur modèle)




FIGURE 14 – Fréquences moyennes pondérées par cluster — AE1_Simple ($k = 20$, déviance = 0,66651). Rouge = au-dessus de la fréquence globale $\bar{f} = 11,85\%$; bleu = en dessous.

Les profils des clusters pour AE2_Deep, VAE1_BCE et VAE2_BCE_Deep sont reportés en annexe F.

4.4 Comparaison globale — Clustering vs GLM vs Réseau de neurones




FIGURE 15 — Déviance de Poisson (moyenne pondérée, ensemble complet) — comparaison de tous les modèles. Plus faible = meilleure performance prédictive.

La figure 15 établit le classement final. Trois enseignements ressortent.

- 1. Supériorité du NN4_Tanh_L1L2.** Le meilleur réseau de neurones (0,65297) devance le GLM Poisson (0,65482), mais l'écart reste très modeste ($\Delta = 0,00185$), confirmant la robustesse du GLM sur des données à dominante catégorielle.
- 2. Écart structurel entre clustering et modèles supervisés.** La déviance du meilleur clustering (AE1_Simple, $k = 20$: 0,66651) reste supérieure à celle du GLM (0,65482), avec un écart de 0,01169. Cet écart est attendu : le K-means optimise l'inertie euclidienne dans l'espace latent, et non la déviance de Poisson directement. La prédiction par fréquence de cluster est une estimation constante par morceaux qui ne peut égaler la souplesse d'un modèle supervisé.
- 3. Faible sensibilité au type d'auto-encodeur.** Les quatre modèles de clustering présentent des performances proches (écart maximal = 0,00751), ce qui suggère que le choix du type d'auto-encodeur (AE ou VAE) a moins d'impact sur la déviance finale que le nombre de clusters k retenu.

A Comparaison par sous-groupes — GLM et NN




FIGURE 16 — Fréquence observée vs GLM Poisson par sous-groupe (validation)




FIGURE 17 — Fréquence observée vs NN4_Tanh_L1L2 par sous-groupe (validation)

B Courbes ICE — GLM Poisson et NN4_Tanh_L1L2

Chaque sous-graphique présente, pour une variable donnée, les courbes ICE individuelles (lignes bleues, $n = 300$ individus tirés aléatoirement) et la courbe PDP moyenne (courbe épaisse colorée).




FIGURE 18 – Courbes ICE — GLM Poisson (rouge = PDP moyen, bleu = individus)




FIGURE 19 – Courbes ICE — NN4_Tanh_L1L2 (vert = PDP moyen, bleu = individus)

C Analyses locales SHAP et LIME — GLM Poisson




FIGURE 20 — SHAP — Police 50612 — GLM Poisson (Prédiction : 0,1293 | Observée : 0,0000)




FIGURE 21 — SHAP — Police 16863 — GLM Poisson (Prédiction : 0,2118 | Observée : 14,2857)




FIGURE 22 – LIME — Police 50612 — GLM Poisson (Prédiction : 0,1293 | Observée : 0,0000)




FIGURE 23 – LIME — Police 16863 — GLM Poisson (Prédiction : 0,2118 | Observée : 14,2857)

D Courbes d'apprentissage — AE et VAE

Les courbes confirment une convergence pour les quatre modèles, sans sur-apprentissage manifeste.

E Courbes d'optimisation K-means

Pour chaque modèle, les figures suivantes présentent l'inertie et la déviance de Poisson en fonction du nombre de clusters k . Le k optimal est sélectionné par




FIGURE 24 – Courbes d'apprentissage des quatre modèles (train et validation)

minimisation de la déviance de Poisson sur l'ensemble de validation.




FIGURE 25 – Optimisation K-means — AE2_Deep




FIGURE 26 – Optimisation K-means — VAE1_BCE




FIGURE 27 – Optimisation K-means — VAE2_BCE_Deep

F Profils de fréquence par cluster — AE2_Deep, VAE1_BCE et VAE2_BCE_Deep




FIGURE 28 – Fréquences moyennes pondérées — AE2_Deep.




FIGURE 29 – Fréquences moyennes pondérées — VAE1_BCE




FIGURE 30 – Fréquences moyennes pondérées