

Institut de Statistique, Biostatistique et Sciences Actuarielles

Projet LDATS 2350

Data Mining

Daktou Tchagam Martial
Kanga Bopda Davy Romaric
Dinock Dinock Yvan Bienvenue

Responsable du cours : **Van Oirbeek Robin**

Table des matières

1	Introduction	1
2	Analyse exploratoire	1
2.1	Prétraitement des données	1
2.2	Analyse descriptive	1
2.3	Détection des valeurs aberrantes	2
2.4	Analyse de la symétrie et de l'aplatissement des variables continues	2
2.5	Inférence statistique (relation avec la cible)	3
3	Modélisation	4
3.1	Régression logistique	4
3.2	Decision Trees	5
3.3	Forêt aléatoire	7
3.4	Gradient boosting	8
3.5	Réseau de neuronne (MLPClassifier)	9
4	Comparaison des performances	10
5	Conclusion	10

1 Introduction

Ce projet de data mining a pour objectif de prédire la survenue d'un accident automobile (`claimNumbMD`) à partir des caractéristiques d'un contrat d'assurance. Le jeu de données contient 24 774 observations décrivant des assurés, leurs véhicules et leur environnement. L'analyse repose sur l'exploration des données, la préparation des variables, l'application de plusieurs modèles prédictifs, et la comparaison de leurs performances afin d'identifier les facteurs les plus influents et la méthode la plus efficace.

2 Analyse exploratoire

2.1 Prétraitement des données

Le jeu de données comprend 24 774 observations et 11 variables . Une première analyse révèle qu'il n'y a aucune valeur manquante : toutes les variables sont complètes. Nous avons éliminé la variable `uwYear` (année de souscription), car elle a servi à créer la variable **nYears**, qui représente déjà l'ancienneté du contrat de manière plus précise. Les variables catégorielles binaires, telles que `claimNumbMD` (la variable cible) et `cover` (le type de couverture), codées en 0/1, ont été renommées en « Non/Oui » pour simplifier l'analyse.

2.2 Analyse descriptive

Variables continues

Les quatre variables numériques clés sont l'âge du conducteur (**age**), l'ancienneté du permis ou de l'assurance (**nYears**), la valeur du véhicule (**carVal**, en euros) et la densité de population (**density**, en habitants/km²). Leur description statistique est la suivante :

1. **Âge des conducteurs** : Les âges varient de 18 à 75 ans, avec une moyenne de 38,6 ans et une médiane de 37 ans. Environ 50 % des conducteurs ont donc moins de 37 ans, ce qui confirme une distribution relativement symétrique centrée sur les âges moyens.
2. **Ancienneté du permis** : Cette variable s'étend de 0 à 15 ans. La moyenne est de 5,3 ans, supérieure à la médiane de 4 ans, ce qui indique que 50 % des conducteurs ont une ancienneté inférieure à 4 ans et suggère une asymétrie à droite (distribution étalée vers les hauts niveaux d'ancienneté).
3. **Valeur des véhicules** : Les montants vont de 1 000 à 49 995 euros, avec une moyenne de 16 772 euros et une médiane de 15 050 euros. Cela signifie que la moitié des véhicules ont une valeur inférieure à 15 050 euros, montrant également une légère asymétrie à droite.
4. **Densité de population** : Les valeurs vont de 14 à 297 habitants/km², avec une moyenne de 127 et une médiane de 111 habitants/km². Ainsi, 50 % des assurés résident dans des zones de densité inférieure à 111 habitants/km², ce qui suggère une concentration plus forte dans les zones rurales ou semi-rurales.

Variables catégorielles

Les variables catégorielles du jeu de données incluent : le genre du conducteur (`gender`), le type de véhicule (`carType`, codé de **A** à **E**), la catégorie de taille du véhicule (`carCat`, avec des valeurs telles que **Small**, **Medium**, **Large**), la profession du conducteur (`job`, comprenant **Employed**, **Self-employed**, **Unemployed**, **Housewife**, **Retired**) et la couverture d'assurance (`cover`, où **Oui** signifie couverture complète et **Non** pour aucune couverture ou couverture partielle). Nous avons une variable ordinale, **carCat**, tandis que les autres variables sont nominales. On observe pour chacune une distribution particulière :


1. **Genre (gender)** : La distribution montre une surreprésentation des hommes (65,8 %) par rapport aux femmes (34,2 %), ce qui indique une population majoritairement masculine parmi les conducteurs assurés.

2. **Type de véhicule (carType)** : Les types A (26,4 %) et B (21,3 %) sont les plus fréquents. Les autres catégories (C, D, E) sont moins représentées, avec un minimum pour le type C (14,0 %). Cela reflète une préférence pour certains segments de véhicules.
3. **Taille du véhicule (carCat)** : La majorité des voitures appartiennent aux catégories Medium (36,7 %) et Large (32,7 %), les voitures Small représentant 30,7 %. Cela montre une répartition relativement équilibrée, sans dominance écrasante.
4. **Profession (job)** : Ceux ayant un emploi sont majoritaire (32,8 %) sont, suivis par des menages (21,7 %) et les indépendants (19,2 %). Les chômeurs (17,1 %) et les retraités (9,1 %) sont en minorité. Cela illustre une certaine diversité socioprofessionnelle.
5. **Couverture (cover)** : La répartition est relativement équilibrée : 51,6 % des assurés n'ont pas souscrit à la couverture matérielle complémentaire, tandis que 48,4 % en bénéficient. Cela suggère que le choix de couverture est partagé presque à parts égales.

Variable cible

La variable cible `claimNumbMD`, représentant la survenance d'un sinistre, présente une distribution relativement équilibrée (voir figure 1) : 50,4 % des assurés n'ont pas déclaré de sinistre, contre 49,6 % ayant eu au moins un sinistre. Cette répartition suggère une sinistralité globalement modérée au sein de la base de donnée analysée.

FIGURE 1 – Distribution de la variable cible



Source : Les auteurs à partir des données

2.3 Détection des valeurs aberrantes

Nous avons appliqué la méthode de l'écart interquartile (IQR) pour détecter les valeurs aberrantes dans les variables numériques. À l'issue de cette méthode, les résultats montrent que seule la variable `carVal` (valeur du véhicule) présente un nombre significatif de valeurs aberrantes, avec **648 observations extrêmes**. Cela peut s'expliquer par la présence de véhicules de très grande valeur. Les autres variables continues (`age`, `nYears`, `density`) ne présentent aucune valeur aberrante selon ce critère. Ces résultats guideront d'éventuelles transformations ou traitements spécifiques avant la modélisation.

2.4 Analyse de la symétrie et de l'aplatissement des variables continues

Les statistiques de symétrie (*skewness*) et d'aplatissement (*kurtosis*) ont été calculées pour les variables continues du jeu de données. **À noter** que dans `pandas`, la fonction `kurt()` retourne l'**excès de kurtosis**, ce qui signifie que la valeur attendue pour une distribution normale est **0** (et non 3 comme dans la définition classique).

Aucune variable ne suit parfaitement une loi normale. Les variables `carVal` et `nYears` montrent une asymétrie marquée à droite, ce qui pourrait nécessiter une transformation (logarithmique, Box-Cox par exemple) avant

Variable	Skewness	Kurtosis	Interprétation
age	0.571	-0.463	Distribution légèrement asymétrique à droite (queue à droite), et plus aplatie que la normale.
nYears	0.629	-0.826	Distribution modérément asymétrique à droite, avec une aplatissement négatif significatif (distribution plate).
carVal	0.951	0.560	Forte asymétrie à droite (valeurs extrêmes élevées) et distribution plus concentrée que la normale.
density	0.479	-1.023	Légère asymétrie à droite, mais distribution très aplatie (très large et peu de concentration autour de la moyenne).

TABLE 1 – Résumé des coefficients de skewness et de kurtosis des variables continues

modélisation. Les kurtosis négatives sur **age**, **nYears** et **density** suggèrent des distributions moins concentrées et plus étalées que la normale, ce qui peut influencer certaines méthodes sensibles aux valeurs extrêmes.

2.5 Inférence statistique (relation avec la cible)

Pour évaluer quelles variables ont un lien significatif avec la survenance d'un sinistre (**claimNumbMD**), nous avons réalisé des tests d'hypothèse. Pour les variables qualitatives, un test du χ^2 d'indépendance a été appliqué ; pour les variables quantitatives, un test non-paramétrique de Kruskal-Wallis a été utilisé (comparant la distribution de la variable continue entre les groupes sinistre Oui/Non). Tous les tests sont menés au niveau de significativité 5%. L'analyse statistique basée sur le test du χ^2 montre que toutes les variables qualitatives considérées (**gender**, **carType**, **carCat**, **job**, **cover**) sont **significativement associées** à la variable cible. Les valeurs de p obtenues sont toutes très faibles (inférieures à 0,05), indiquant un **rejet de l'hypothèse d'indépendance**. L'intensité de l'association a été mesurée via le **V de Cramer** :

- Les valeurs obtenues sont relativement **faibles (inférieures à 0,25)**, suggérant que bien que l'association soit significative, **elle reste de faible intensité**.
- La variable **job** est celle qui présente **la plus forte association** ($V \approx 0,21$), suivie par **carCat** et **cover**.

Pour les variables continues (**age**, **nYears**, **carVal**, **density**), un **test de Kruskal-Wallis** a été réalisé et les résultats montrent que **toutes ces variables ont un effet significatif** sur la variable cible, avec des p -values très proches de 0. Cela indique que la distribution de la variable cible varie **significativement selon les valeurs de ces variables quantitatives**.

TABLE 2 – Résultats des tests d'association entre les variables explicatives et la variable cible

Variable	Test statistique	Résultat
gender	Test du χ^2	p-value = $1,47 \times 10^{-13}$
carType	Test du χ^2	p-value = $3,23 \times 10^{-18}$
carCat	Test du χ^2	p-value = $4,30 \times 10^{-40}$
job	Test du χ^2	p-value = $5,86 \times 10^{-226}$
cover	Test du χ^2	p-value = $6,80 \times 10^{-33}$
age	Test de Kruskal-Wallis	p-value < $2,2 \times 10^{-16}$
nYears	Test de Kruskal-Wallis	p-value = $8,70 \times 10^{-22}$
carVal	Test de Kruskal-Wallis	p-value = $1,12 \times 10^{-7}$
density	Test de Kruskal-Wallis	p-value = $6,67 \times 10^{-134}$

3 Modélisation

3.1 Régression logistique

Discrétisation des données

Dans cette section, nous avons dans un premier temps implémenté un modèle de régression logistique *sans* discrétisation des variables continues, après traitement des valeurs aberrantes de la variable `carVal`. Toutefois, cette première approche n'a pas permis d'obtenir un modèle de qualité satisfaisante.

Pour améliorer la performance, nous avons ensuite procédé à une discrétisation supervisée des variables continues. Cette étape a été réalisée à l'aide de modèles d'arbres de décision univariés (une variable continue et la variable cible) afin d'identifier les points de coupure optimaux. Les seuils ainsi obtenus ont été validés à l'aide de la métrique du *Weight of Evidence* (WOE) et de sa synthèse globale, la *Information Value* (IV).

- La variable `age` présente une IV supérieure à 0,3, indiquant une segmentation très pertinente.
- La variable `density` présente une IV comprise entre 0,1 et 0,3, correspondant à une qualité de segmentation moyenne mais exploitable.
- Les variables `carVal` et `nYears` affichent une IV faible (inférieure à 0,1), traduisant une segmentation peu informative. Toutefois, aucune amélioration significative n'a pu être obtenue via d'autres méthodes de découpage.

Afin de construire un modèle à la fois parsimonieux et robuste, nous avons appliqué une procédure de sélection de variables par *Backward elimination*, fondée sur le critère d'information d'Akaike (AIC).

Le modèle initial incluait 9 variables explicatives : les 5 variables qualitatives (`gender`, `carType`, `carCat`, `job`, `cover`) ainsi que les 4 variables continues discrétisées (`age_bin`, `nYears_bin`, `carVal_bin`, `density_bin`).

Le jeu de données a été divisé en deux ensembles distincts : un jeu d'apprentissage (75%) et un jeu de test (25%) afin d'évaluer la robustesse et la généralisation du modèle.

Résultats du modèle

Le modèle de régression logistique a permis d'identifier plusieurs prédicteurs significatifs du risque de sinistre (`claimNumbMD`). Parmi les résultats marquants :

- Le sexe féminin est associé à une probabilité de sinistre plus faible.
- Les types de véhicules B, C, D et E présentent des risques plus élevés par rapport au type A.
- Les retraités ont un risque nettement plus faible que les employés, tandis que les personnes au foyer ou sans emploi ont un risque accru.
- La présence d'une couverture matérielle augmente significativement la probabilité de sinistre.

Le pseudo- R^2 de McFadden atteint 0.041, ce qui est cohérent avec les attentes pour ce type de modèle. Le test du Log-Likelihood Ratio confirme la significativité globale du modèle avec $p < 0.001$.

Sélection de variables par méthode backward

Pour simplifier le modèle sans perdre en performance, nous avons utilisé la méthode de sélection backward. Cette méthode commence avec toutes les variables, puis retire celles qui n'apportent pas assez d'information selon le critère AIC. Après trois itérations, les variables `carCat` et `cover` ont été supprimées. Le modèle final sélectionné contient les variables suivantes : `gender`, `carType`, `job`, `carVal_bin`, `age_bin`, `density_bin`, `nYears_bin`.

Résultats du modèle final

Le tableau ci-dessous présente les coefficients et la significativité (p-value) des variables les plus importantes dans le modèle final :

TABLE 3 – Résultats de la regression logistique

	coef	std err	z	P> z	[0.025	0.975]
Intercept	0.5722	0.083	6.909	0.000	0.410	0.735
C(gender, Treatment(reference='Male'))[T.Female]	-0.2264	0.033	-6.796	0.000	-0.292	-0.161
C(carType, Treatment(reference='A'))[T.B]	0.1285	0.046	2.808	0.005	0.039	0.218
C(carType, Treatment(reference='A'))[T.C]	0.1703	0.052	3.286	0.001	0.069	0.272
C(carType, Treatment(reference='A'))[T.D]	0.2513	0.046	5.445	0.000	0.161	0.342
C(carType, Treatment(reference='A'))[T.E]	0.3529	0.048	7.377	0.000	0.259	0.447
C(job, Treatment(reference='Employed'))[T.Housewife]	0.2311	0.044	5.288	0.000	0.145	0.317
C(job, Treatment(reference='Employed'))[T.Retired]	-0.9932	0.084	-11.875	0.000	-1.157	-0.829
C(job, Treatment(reference='Employed'))[T.Self-employed]	-0.1948	0.045	-4.351	0.000	-0.283	-0.107
C(job, Treatment(reference='Employed'))[T.Unemployed]	0.1976	0.046	4.320	0.000	0.108	0.287
C(carVal_bin, Treatment(reference='[1000 ; 10167.5]'))[T.[10167.5 ; 10517.5]]	-0.1832	0.165	-1.107	0.268	-0.507	0.141
C(carVal_bin, Treatment(reference='[1000 ; 10167.5]'))[T.[10517.5 ; 10572.5]]	1.1874	0.425	2.792	0.005	0.354	2.021
C(carVal_bin, Treatment(reference='[1000 ; 10167.5]'))[T.[10572.5 ; 20357.5]]	0.0456	0.038	1.190	0.234	-0.030	0.121
C(carVal_bin, Treatment(reference='[1000 ; 10167.5]'))[T.[20357.5 ; 20982.5]]	0.1948	0.120	1.629	0.103	-0.040	0.429
C(carVal_bin, Treatment(reference='[1000 ; 10167.5]'))[T.[20982.5 ; 21167.5]]	0.9809	0.249	3.944	0.000	0.493	1.468
C(carVal_bin, Treatment(reference='[1000 ; 10167.5]'))[T.[21167.5 ; 21265.0]]	0.0901	0.349	0.258	0.796	-0.594	0.774
C(carVal_bin, Treatment(reference='[1000 ; 10167.5]'))[T.[21265.0 ; 21307.5]]	1.0942	0.706	1.550	0.121	-0.289	2.478
C(carVal_bin, Treatment(reference='[1000 ; 10167.5]'))[T.[21307.5 ; 21432.5]]	-0.2491	0.277	-0.899	0.369	-0.792	0.294
C(carVal_bin, Treatment(reference='[1000 ; 10167.5]'))[T.[21432.5 ; 50044.99]]	0.1927	0.039	4.926	0.000	0.116	0.269
C(age_bin, Treatment(reference=0))[T.[20.5 ; 22.5]]	-0.1447	0.091	-1.581	0.114	-0.324	0.035
C(age_bin, Treatment(reference=0))[T.[22.5 ; 25.5]]	-0.2602	0.081	-3.194	0.001	-0.420	-0.101
C(age_bin, Treatment(reference=0))[T.[25.5 ; 29.5]]	-0.4857	0.076	-6.416	0.000	-0.634	-0.337
C(age_bin, Treatment(reference=0))[T.[29.5 ; 32.5]]	-0.8835	0.082	-10.818	0.000	-1.044	-0.723
C(age_bin, Treatment(reference=0))[T.[32.5 ; 47.5]]	-1.1599	0.066	-17.570	0.000	-1.289	-1.031
C(age_bin, Treatment(reference=0))[T.[47.5 ; 52.5]]	-1.2685	0.083	-15.194	0.000	-1.432	-1.105
C(age_bin, Treatment(reference=0))[T.[52.5 ; 60.5]]	-1.3626	0.081	-16.832	0.000	-1.521	-1.204
C(age_bin, Treatment(reference=0))[T.[60.5 ; 71.5]]	-1.3924	0.102	-13.593	0.000	-1.593	-1.192
C(age_bin, Treatment(reference=0))[T.[71.5 ; 75.07]]	-0.9631	0.132	-7.272	0.000	-1.223	-0.704
C(density_bin, Treatment(reference=0))[T.[151.04 ; 251.14]]	0.6289	0.040	15.654	0.000	0.550	0.708
C(density_bin, Treatment(reference=0))[T.[251.14 ; 274.03]]	1.2024	0.082	14.608	0.000	1.041	1.364
C(density_bin, Treatment(reference=0))[T.[274.03 ; 297.68]]	0.7733	0.068	11.365	0.000	0.640	0.907
C(density_bin, Treatment(reference=0))[T.[297.68 ; 308.08]]	0.3008	0.040	7.591	0.000	0.223	0.378
C(nYears_bin, Treatment(reference=0))[T.[0.5 ; 4.5]]	-0.1249	0.047	-2.638	0.008	-0.218	-0.032
C(nYears_bin, Treatment(reference=0))[T.[13.5 ; 15.01]]	-0.4073	0.073	-5.610	0.000	-0.550	-0.265
C(nYears_bin, Treatment(reference=0))[T.[4.5 ; 9.5]]	-0.2114	0.051	-4.155	0.000	-0.311	-0.112
C(nYears_bin, Treatment(reference=0))[T.[9.5 ; 13.5]]	-0.3025	0.057	-5.274	0.000	-0.415	-0.190

Source : Les auteurs à partir des données

Ces résultats montrent que certains profils ont un effet marqué sur la probabilité de sinistre. Par exemple, être une femme ou un conducteur âgé entre 30 et 50 ans diminue le risque. À l'inverse, conduire une voiture de type E, être sans emploi ou vivre dans une zone très dense augmente ce risque.

Évaluation des performances

Le modèle a été évalué à l'aide de métriques classiques telles que la précision, le rappel et le F1-score sur les jeux d'entraînement et de test. Les résultats sont stables entre les deux ensembles, avec une accuracy d'environ 64,5%. Le F1-score pour la classe des sinistres atteint 0,638 sur le jeu d'apprentissage et 0,633 sur le test, ce qui indique une bonne capacité à équilibrer précision et recall. Le modèle montre une généralisation satisfaisante sans surapprentissage apparent. Ces résultats, bien que perfectibles, sont conformes aux attentes pour une première approche de classification dans un contexte assurantiel.

TABLE 4 – Classification metrics for logistic regression

Set	Accuracy	Precision (class 1)	Recall (class 1)	F1-score (class 1)
Train	0.6446	0.6419	0.6319	0.6380
Test	0.6458	0.6508	0.6175	0.6334

3.2 Decision Trees

Préparation des données

Les variables explicatives ont été préparées en combinant les variables continues brutes (`age`, `carVal`, `nYears`, `density`) et les variables catégorielles encodées par **one-hot encoding** (`gender`, `carType`, `carCat`, `job`, `cover`). La variable cible `claimNumbMD` a été transformée en variable binaire (1 = sinistre, 0 = aucun sinistre). L'échantillon a été divisé en deux parties : 80% pour l'entraînement (avec validation croisée) et 20% pour le test.

Construction du modèle

Un arbre de décision a été entraîné à l'aide de `GridSearchCV` avec validation croisée à 5 plis, en explorant différentes combinaisons d'hyperparamètres : profondeur maximale, critère de division (`gini`, `entropy`, `log_loss`), nombre minimum d'échantillons par nœud/feuille, et nombre maximal de variables considérées à chaque division. La grille a été évaluée selon plusieurs métriques de performance : AUC, accuracy, précision, rappel, F1-score et log-loss.

Résultats et interprétation

Les meilleurs scores obtenus sont les suivants :

- AUC : 0.6807 (avec `max_depth=5`, `criterion=entropy`)
- Accuracy : 0.6355
- Precision : 0.6558
- Recall : 0.6745
- F1-score : 0.6449
- LogLoss : -0.6417

Les résultats montrent un bon équilibre entre précision et rappel, avec un F1-score compétitif. Le critère `entropy` semble favoriser une meilleure précision, tandis que `gini` donne de meilleures performances en rappel et F1-score.

L'analyse des importances des variables révèle que l'âge du conducteur est de loin le facteur prédictif dominant dans l'arbre de décision, représentant à lui seul plus de 50% de l'importance totale. La densité de population (`density`) et le fait d'être retraité (`job_Retired`) apparaissent également comme des variables influentes. À l'inverse, des variables telles que `carVal`, `carType_E` ou encore certaines modalités de profession (par exemple `job_Unemployed`) ont un poids beaucoup plus faible dans les décisions prises par le modèle.

Évaluation des performances

Le modèle final a été évalué sur les ensembles d'entraînement et de test. Les résultats montrent une stabilité remarquable entre les deux jeux, avec une `accuracy` d'environ 64% dans les deux cas. Sur la classe positive (sinistres), le modèle obtient un F1-score de 0,615 en entraînement et 0,614 en test, ce qui indique une bonne capacité de généralisation. La précision pour cette classe est de 0,655 en apprentissage et de 0,656 en test, tandis que le rappel reste stable à 0,58. Le modèle parvient donc à capter une part raisonnable des sinistres tout en limitant les faux positifs, ce qui est un compromis souvent recherché en assurance.

TABLE 5 – Classification metrics for decision tree

Set	Accuracy	Precision (class 1)	Recall (class 1)	F1-score (class 1)
Train	0.6407	0.6553	0.5802	0.6155
Test	0.6406	0.6562	0.5768	0.6139

TABLE 6 – Classification metrics for decision tree

Set	Accuracy	Precision (class 1)	Recall (class 1)	F1-score (class 1)
Train	0.6407	0.6553	0.5802	0.6155
Test	0.6406	0.6562	0.5768	0.6139

La courbe ROC ci-dessus montre une performance relativement stable entre les données d'entraînement et celles de test, avec une aire sous la courbe (AUC) de 0.690 et 0.692 respectivement. Cette proximité des courbes indique une bonne généralisation du modèle, sans signe de surapprentissage.

Le meilleur modèle final retenu est un arbre de décision avec une profondeur maximale de 5 et un minimum de 20 observations par feuille. Ce paramétrage a été identifié comme optimal en minimisant la log-loss, ce qui garantit

une bonne calibration des probabilités prédites. Ce modèle constitue un bon compromis entre interprétabilité et performance. L’analyse des importances des variables, telle que calculée par l’arbre de décision, met en évidence l’influence dominante de l’âge du conducteur, qui représente plus de 50 % de l’importance totale du modèle. Cette variable apparaît comme un déterminant majeur du risque de sinistre. La densité de population (**density**) arrive en seconde position, suggérant que les conducteurs vivant dans des zones plus denses présentent un comportement ou une exposition au risque différent. Le statut professionnel, notamment le fait d’être retraité (**job_Retired**), est également une variable fortement contributive. À l’inverse, certaines modalités spécifiques, comme **carType_E** ou **job_Unemployed**, n’ont qu’un impact marginal sur les décisions prises par l’arbre. Cette hiérarchie d’importance permet de mieux comprendre les facteurs clés du modèle et peut orienter des actions de tarification ou de prévention ciblées.




FIGURE 2 – Importance des variables selon l’arbre de décision




FIGURE 3 – Courbes ROC pour l’arbre de décision (train vs test)

3.3 Forêt aléatoire

La forêt aléatoire est l’un des modèles d’ensemble qui permet de palier les insuffisances de l’arbre de décision notamment la dépendance de ses performances avec l’échantillon. Il est donc paru opportun d’ajuster une forêt aléatoire sur les données et de l’intégrer dans le paysage des modèles à comparer. Les paramètres utilisés pour la construction de la forêt aléatoire sont les suivants :

TABLE 7 – Paramètres d’entraînement de la forêt aléatoire

Nombre d’arbres	100
Profondeur maximale d’un arbre	5
Taille minimale d’un noeud pour un split	7
Taille minimale d’une feuille	20
Bootstrap (tirage avec remise)	oui

Source : travaux des auteurs

En termes de performances dans la classification, la forêt entraînée présente les métriques suivantes de tableau 8 sur les ensembles test et entraînement. Compte-tenu des objectifs, le modèle se doit de minimiser les faux négatifs et donc maximiser le recall. Le recall de 65% obtenu dans l’ensemble test est assez satisfaisant. Tout aussi proche du recall, la précision (64%) qui donne la probabilité d’avoir un sinistre sachant que le modèle indique qu’il y aura sinistre est également acceptable.

TABLE 8 – Métriques de classification de la forêt aléatoire

Set	Accuracy	Precision	Recall	F1-score
Train	0.65	0.64	0.65	0.64
Test	0.64	0.64	0.64	0.64

Source : travaux des auteurs

Pour ce qui est de l’importance des variables dans la prédiction de l’occurrence d’un sinistre chez un assuré et des performances globales du modèle, l’on a les deux graphiques ci-dessous.




FIGURE 4 – Importance des variables selon le gradient boosting




FIGURE 5 – Courbes ROC pour le gradient boosting (train vs test)

Source : travaux des auteurs

Il ressort que la variable la plus importance dans la prévision de l’occurence d’un sinistre est l’âge suivi de la modalité retraité de la profession. Cela peut également se comprendre intuitivement. L’âge jeune renforce la probabilité d’occurence pour les jeunes conducteurs qui peuvent être insouciant au volant. A l’opposé, les retraités sont des personnes relativement âgés (65 ans ou plus), qui jouissent a priori d’une bonne expérience dans la conduite. Cela limite l’occurence de sinistre dans cette catégorie d’assurés qu’est les retraités. L’âge et le statut retraité peuvent donc être vu comme deux format d’âge qui apportent la même information.

Pour ce qui est de la capacité de classement du modèle, l’aire sous la courbe ROC dans l’ensemble test qui est d’environ 0.698 (environ 70%) indique que le modèle classe relativement bien les VR positifs, i. e les assurés qui sont réellement susceptible d’avoir un sinistre. Cela est tout à fait acceptable en termes de performance.

3.4 Gradient boosting

Le modèle Gradient Boosting est construit avec les paramètres suivants : Dans les ensembles d’entraînement

TABLE 9 – Paramètres de construction du Gradient Boosting

Nombre d’arbres	100
Taux d’apprentissage	0.1
Profondeur maximale	5
Taille minimale pour un split	5
Taille minimale d’une feuille	2
Nombre de caractéristiques à considérer	$\sqrt{10}$

Source : travaux des auteurs

et de tests, le gradient boosting donne des AUC similaires soit respectivement 0.7471 et 0.6993 ce qui indique que la performance est indépendante de l’échantillon et donc qu’il n’y a pas de suraPprentissage.

Pour ce qui concerne ses métriques de classification, elles sont résumées dans le tableau ci-dessous. Rappelons que compte tenu du coût pour l’assureur qu’engendre la survenue d’un sinistre chez un assuré, la bonne métrique est celle qui minimise les faux négatifs et est à ce titre le recall. L’on constate que le recall dans la class 1. L’on a un recall dans la classe 1 ce qui est acceptable. Par ailleurs, la précision est tout aussi acceptable (64%) dans les deux ensembles.

TABLE 10 – Métriques de performance du gradient boosting dans la classe 1

Ensemble	accuracy	precision	recall	F1-score
Train	0.68	0.683815	0.648239	0.665552
Test	0.64	0.646932	0.609776	0.627805

Source : travaux des auteurs

Pour ce qui concerne l’importance de chacune des variables dans la prévision de la survenue d’un sinistre, la situation est résumée dans le graphique suivant. L’on constate que comme pour les modèles précédents, l’âge et la

densité sont les variables qui contribuent le mieux à expliquer la survenue d'un sinistre chez un assuré. Cela est tout à fait intuitif. les jeunes conducteurs étant en général moins expérimentés et plus audacieux au volant, il est plus vraisemblable d'avoir un sinistre chez les jeunes assurés. Par ailleurs, la densité de la population vient moduler le risque d'accident car plus une zone est dense plus les automobilistes sont exposés au risque d'accident car étant potentiellement plus nombreux ou pouvant potentiellement heurter plus de personnes. A droite du graphique sur l'importance, se trouve la courbe ROC qui montre que pour l'ensemble test, l'AUC est d'environ 70%. C'est un résultat raisonnable qui indique un modèle une bonne qualité.




FIGURE 6 – Importance des variables selon le gradient boosting




FIGURE 7 – Courbes ROC pour le gradient boosting (train vs test)

Source : travaux des auteurs

3.5 Réseau de neurone (MLPClassifier)

Enfin, nous avons entraîné un réseau de neurones multi-couche (Multi-Layer Perceptron - MLP) pour modéliser la probabilité de survenance d'un sinistre. Les variables explicatives numériques ont été préalablement standardisées (centrées et réduites) à l'aide de la méthode **StandardScaler**, afin d'accélérer la convergence de l'algorithme d'optimisation et de garantir une échelle homogène entre les variables. Le modèle retenu repose sur l'architecture suivante :

- **Architecture** : Deux couches cachées contenant respectivement 100 et 50 neurones.
- **Fonction d'activation** : ReLU (Rectified Linear Unit), bien adaptée à des architectures profondes.
- **Optimiseur** : Adam, un algorithme de gradient stochastique performant combinant momentum et adaptation du taux d'apprentissage.
- **Régularisation** : Terme de pénalisation L_2 avec $\alpha = 0,001$ pour limiter le surapprentissage.
- **Taux d'apprentissage** : Adaptatif (adaptive), ajusté dynamiquement durant l'apprentissage.
- **Critère d'arrêt** : early stopping avec une fraction de 10 % des données de validation pour interrompre l'entraînement lorsque la performance se stabilise.
- **Itérations maximales** : 500 itérations.

Après entraînement sur les données standardisées, les performances obtenues sont les suivantes :

- **AUC sur l'échantillon d'apprentissage** : $AUC_{\text{train}} = 0,907$
- **AUC sur l'échantillon de test** : $AUC_{\text{test}} = 0,864$

Évaluation du réseau de neurones

Le modèle de réseau de neurones atteint une exactitude de 64 % sur l'ensemble d'entraînement et de 63,5 % sur l'échantillon de test, indiquant une performance stable mais modérée. Le F1-score est de 0,61 pour la classe sinistre et 0,63 pour la classe sans sinistre sur les données de test. La sensibilité est légèrement meilleur pour les non-sinistres (0,69) que pour les sinistres (0,57), ce qui suggère que le modèle identifie mieux l'absence de

sinistre. Globalement, le modèle montre un pouvoir prédictif correct mais sans gain notable par rapport aux autres méthodes, tout en offrant une alternative non linéaire intéressante.

4 Comparaison des performances

Tous les modèles testés offrent une performance relativement proche. Nous résumons ci-dessous les AUC obtenus en train et test, ainsi que l'écart (surdifférence) entre les deux :

TABLE 11 – Comparaison des performances des modèles (AUC)

Modèle	AUC Train	AUC Test	Écart (Train - Test)
Régression logistique	0.6980	0.7010	-0.0030
Arbre de décision	0.6905	0.6922	-0.0018
Gradient Boosting	0.7471	0.6993	0.0478
Bagging	0.7046	0.7008	0.0038
Neural Network	0.7006	0.6934	0.0072
Random Forest	0.7006	0.6982	0.0024

En termes de stabilité, l'ensemble des modèles présente de très faibles écarts entre les performances en apprentissage et en test, ce qui témoigne d'une bonne capacité de généralisation. Sur l'échantillon de test, le *modèle de régression logistique* se distingue par la meilleure généralisation, suivi de près par le modèle de *Bagging*.

Compte tenu des performances comparables entre les différentes approches, il est pertinent de privilégier les modèles simples et interprétables. À cet égard, la régression logistique constitue une option de choix : elle permet une lecture directe des effets des variables explicatives tout en maintenant un niveau de performance proche de celui des modèles ensemblistes plus complexes.

5 Conclusion

L'analyse met en évidence plusieurs facteurs de risque significatifs pour la survenue d'un sinistre automobile. D'abord, l'âge apparaît comme un facteur protecteur : comparés aux jeunes conducteurs de 18 à 20.5 ans, les profils plus âgés présentent une probabilité de sinistre nettement plus faible, cette tendance étant d'autant plus marquée à partir de 25 ans. Ensuite, la densité de population est également déterminante : les conducteurs vivant dans des zones urbaines denses (> 77.71 hab/km²) présentent un risque accru, particulièrement marqué entre 251 et 274 hab/km². Ces résultats soulignent l'impact du contexte de circulation sur le risque routier. Le statut professionnel influence aussi la sinistralité : les retraités et indépendants présentent un risque inférieur à celui des salariés, tandis que les chômeurs et technicien de surface sont plus exposés, probablement en lien avec des usages différenciés du véhicule. En ce qui concerne les modèles prédictifs, la régression logistique binarisée se distingue par sa simplicité, sa transparence et une performance proche des modèles ensemblistes. Elle est particulièrement adaptée dans un cadre réglementaire ou pour justifier une tarification. Toutefois, pour maximiser la performance prédictive, des modèles comme le Bagging ou la Forêt aléatoire peuvent être envisagés. Les gains marginaux apportés par le Boosting ou les réseaux de neurones ne compensent pas leur complexité dans ce cas d'usage. En conclusion, nous recommandons l'usage de la **régression logistique** comme modèle principal, complétée par des règles issues des arbres de décision pour des actions de prévention ciblées. Ces résultats peuvent guider la stratégie de souscription, notamment par une surveillance accrue des jeunes conducteurs en milieu urbain, afin de mieux maîtriser le risque de sinistralité.

Annexe

Lien vers le fichier partagé Google Colab où se trouvent toutes les sorties réalisées sur Python :
 Accéder au notebook sur Google Colab